Take Home Exam (프로젝트) 2차 보고서

20241989 최은지

1. 문제의 정의

* 최종 목표

: 당뇨병 발병에 영향을 미치는 요인들 중에서 어떤 요인이 더 큰 영향을 미치는지를 분석한다.

* 연구 가설

: 유전적 요인보다 BMI와 인슐린 수치가 당뇨병 발병에 더 큰 영향을 미칠 것이다.

① 각 요인이 당뇨병 진단(Outcome)에 미치는 상대적 영향은 어느 정도인가?
② Age(나이) 등의 보조 변수는 주요 요인들과 어떤 상관관계를 가지는가?
③ 유전적 요인보다 BMI와 인슐린 수치가 더 큰 영향을 보이는가?

- 이진 분류 모델

2. 데이터 정의

https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database

샘플 수: 768개

변수 수: 9개 (입력 8개, 출력 1개)

입력변수 : Pregnancies(임신 횟수), Glucose(혈당 수치), BloodPressure(혈압), SkinTickness(피부 두께), insulin(인슐린 수치), BMI(체질량지수), DiabetesPedigreeFunction(가족력지표, 유전적요인), age(나이)

출력변수 : outcome(당뇨병 여부)

3. 데이터의 처리 과정

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
```

```python
df = pd.read_csv("diabetes.csv")

zero_as_na_cols = ["Glucose", "BloodPressure", "SkinThickness", "Insulin", "BMI"

df[zero_as_na_cols] = df[zero_as_na_cols].replace(0, np.nan)

print("< 0 -> NaN 변환 후 결측치 개수 >")
print(df.isna().sum())

for col in zero_as_na_cols:
    df[col] = df[col].fillna(
        df.groupby("Outcome")[col].transform("median")
    )

print("< 결측치 처리 후 개수 >")
print(df.isna().sum())
```

```
< 0 -> NaN 변환 후 결측치 개수 >
Pregnancies                 0
Glucose                     5
BloodPressure              35
SkinThickness             227
Insulin                   374
BMI                        11
DiabetesPedigreeFunction    0
Age                         0
Outcome                     0
dtype: int64
< 결측치 처리 후 개수 >
Pregnancies                 0
Glucose                     0
BloodPressure               0
SkinThickness               0
Insulin                     0
BMI                         0
DiabetesPedigreeFunction    0
Age                         0
Outcome                     0
dtype: int64
```

먼저 2번에서 정의한 데이터셋을 diabetes.csv 파일에서 불러와 DataFrame 형태로 저장하였다. 변수 중 0이 될 수 없음에도 값에 0이 포함되어 있는 Glucose, BloodPressure, SkinThickness, Insulin, BMI의 0값들을 결측치로 간주하여 0을 NaN으로 변환하였다.

그 후 각 변수별 결측치 개수를 출력하여 결측 현황을 확인하였으며, 결측치가 존재하는 열에 대해서는 당뇨병 진단 결과(Outcome, 0: 비당뇨, 1: 당뇨)를 기준으로 그룹을 나눈 뒤, 각 그룹의 중앙값으로 결측치를 대체하였다. 극단값의 영향을 완화하고, 동시에 당뇨 여부에 따른 분포 차이를 반영하기 위해서 중앙값을 사용하였다. 결측치 대체 이후에는 확인을 위해 다시 결측치 개수를 출력하여 모든 결측치가 잘 처리되었음을 확인하였다.

```python
cols_to_check = ["Glucose", "Insulin", "BMI"]

plt.figure(figsize=(5, 3))
df[cols_to_check].boxplot()
plt.title("Glucose / Insulin / BMI")
plt.ylabel("value")
plt.show()
```

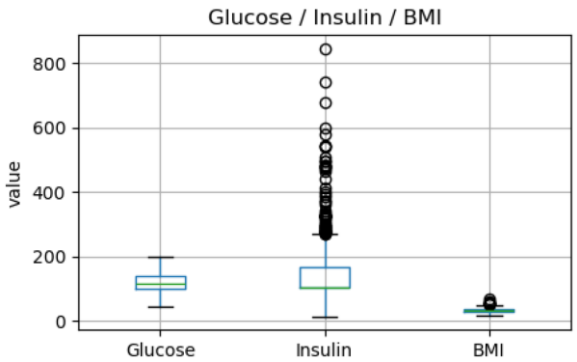

이후 Glucose, Insulin, BMI 세 변수를 대상으로 그래프를 그려 값의 분포와 극단값 후보를 시각적으로 확인하였다. Insulin의 경우 이상치로 고려되는 값들이 존재하였으나, 실제 임상적으로 당뇨병 환자의 경우 인슐린 수치가 매우 높게 측정될 수 있는 점을 고려하여 그대로 유지하였다.

```python
X = df.drop("Outcome", axis=1)
y = df["Outcome"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

print("\nX_train:", X_train.shape, " X_test:", X_test.shape)
print("y_train:", y_train.shape, " y_test:", y_test.shape)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

X_train_scaled = pd.DataFrame(X_train_scaled, columns=X.columns)
X_test_scaled = pd.DataFrame(X_test_scaled, columns=X.columns)

train_df = pd.concat(
    [X_train_scaled.reset_index(drop=True),
     y_train.reset_index(drop=True)],
    axis=1
)
test_df = pd.concat(
    [X_test_scaled.reset_index(drop=True),
     y_test.reset_index(drop=True)],
    axis=1
)

train_df.to_csv("diabetes_train_preprocessed.csv", index=False)
test_df.to_csv("diabetes_test_preprocessed.csv", index=False)
```

```
X_train: (614, 8)  X_test: (154, 8)
y_train: (614,)  y_test: (154,)
```

앞에서 전처리한 데이터에서 타깃 변수인 Outcome을 분리하고, 나머지 변수들을 입력 변수 X로 설정한 뒤, train_test_split을 사용해 데이터를 학습용 80%, 테스트용 20%로 분할하였다. 이때 stratify=y로 당뇨/비당뇨 비율을 유지하고, random_state=42로 난수를 고정해 재현 가능성을 확보하였다. 입력 변수는 StandardScaler로 표준화하였으며, 학습용 데이터에 대해서만 평균과 표준편차를 추정해 fit한 후, 같은 변환을 학습용·테스트용 데이터에 transform으로 적용하여 데이터 누수를 방지하였다. 스케일링된 입력 변수와 타깃을 결합해 학습용·테스트용 데이터프레임을 구성하고, 이를 각각 csv 파일로 저장하여 이후 모델 학습 및 평가에 활용할 수 있도록 하였다.

4. 머신러닝 모델의 튜닝 과정

본 연구에서는 당뇨병 여부를 예측하기 위해 해석 가능성이 높은 로지스틱 회귀 모형을 사용하였다. 로지스틱 회귀는 각 독립변수가 당뇨병 진단 결과에 미치는 영향을 회귀계수와 승산비)의 형태로 제시할 수 있어,

① 각 요인의 상대적 영향력 비교,
② 보조 변수(Age 등)와 주요 변수 간의 관계 해석,
③ 유전적 요인(DiabetesPedigreeFunction)과 BMI, Insulin의 영향력 비교

라는 연구 질문을 분석하기에 적합하다.

또한 복잡한 비선형 모델에 비해, 로지스틱 회귀는 계수 해석이 직관적이고, 변수 선택 및 규제를 통해 과적합을 제어할 수 있다는 장점이 있다. 모델의 일반화 성능과 해석 가능성을 살펴보기 위해 다음과 같이 3가지 파라미터 설정을 사전에 계획하였다.

<Model 1> 기본 L2 규제 모형

- penalty="l2", C=1.0, class_weight=None, solver="liblinear"

- 기준(baseline) 성능과 계수 분포를 확인하기 위한 기본 모형.

<Model 2> 강한 L2 규제 모형

- penalty="l2", C=0.1, class_weight=None, solver="liblinear"

- 계수를 더 강하게 축소하여, 중요한 변수와 그렇지 않은 변수를 더 뚜렷이 구분하고 과적합 가능성을 줄이기 위한 설정.

<Model 3> 클래스 불균형 보정 모형

- penalty="l2", C=1.0, class_weight="balanced", solver="liblinear"

- 당뇨/비당뇨 비율 차이를 보정하여, 소수 클래스(당뇨)에 대한 재현율을 개선할 수 있는지 확인하기 위한 설정.

이 세 가지 모형의 성능 지표 및 계수/승산비를 비교하여, 연구 질문 ①~③에 대한 결론을 도출하였다.

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, roc_auc_score

train = pd.read_csv("diabetes_train_preprocessed.csv")
test = pd.read_csv("diabetes_test_preprocessed.csv")

X_train = train.drop("Outcome", axis=1)
y_train = train["Outcome"]

X_test = test.drop("Outcome", axis=1)
y_test = test["Outcome"]

feature_names = X_train.columns
```

먼저, 전처리된 학습용 데이터와 테스트용 데이터를 불러온 뒤, 타깃 변수 Outcome을 분리하여 y_train, y_test로 두고 나머지 변수를 입력변수 X_train, X_test로 설정하였다. 이후의 모든 모형은 동일한 데이터 분할을 사용하여, 파라미터 설정에 따른 성능 및 계수 차이를 공정하게 비교할 수 있도록 하였다.

```python
def fit_and_collect(name, penalty, C, class_weight, solver="liblinear", max_iter
    model = LogisticRegression(
        penalty=penalty,
        C=C,
        class_weight=class_weight,
        solver=solver,
        random_state=42,
        max_iter=max_iter
    )
    model.fit(X_train, y_train)

    y_pred = model.predict(X_test)
    y_proba = model.predict_proba(X_test)[:, 1]

    auc = roc_auc_score(y_test, y_proba)
    report_dict = classification_report(y_test, y_pred, output_dict=True)
    report_df = pd.DataFrame(report_dict).T

    coef = model.coef_[0]
    coef_df = pd.DataFrame({
        "feature": feature_names,
        "coef": coef,
        "odds_ratio": np.exp(coef)
    })
    coef_df["abs_coef"] = coef_df["coef"].abs()
    coef_df = coef_df.sort_values("abs_coef", ascending=False)

    return {
        "name": name,
        "model": model,
        "auc": auc,
        "report_df": report_df,
        "coef_df": coef_df
    }
```

세 가지 파라미터 조합을 반복적으로 평가하기 위해, 공통적으로 사용할 함수를 정의하였다. 이 함수는 주어진 파라미터로 로지스틱 회귀 모형을 학습한 후, 테스트 데이터에 대한 ROC-AUC 점수, 분류 지표(precision, recall, F1-score)를 담은 테이블, 각 변수의 계수와 승산비(odds ratio)를 계산하여 하나의 결과 객체로 반환한다. 계수와 승산비는 연구 질문 ①, ③ 분석에, 분류 성능은 모형 선택의 근거로 사용된다.

```python
results = []

results.append(
    fit_and_collect(
        name="Model 1",
        penalty="l2",
        C=1.0,
        class_weight=None
    )
)

results.append(
    fit_and_collect(
        name="Model 2",
        penalty="l2",
        C=0.1,
        class_weight=None
    )
)

results.append(
    fit_and_collect(
        name="Model 3",
        penalty="l2",
        C=1.0,
        class_weight="balanced"
    )
)

model_names = [r["name"] for r in results]
auc_values = [r["auc"] for r in results]
f1_positive = [r["report_df"].loc["1", "f1-score"] for r in results]

plt.figure(figsize=(5, 3))
plt.bar(model_names, auc_values)
plt.ylabel("ROC-AUC")
plt.ylim(0, 1)
plt.title("ROC-AUC by model")
plt.xticks(rotation=15)
plt.tight_layout()
plt.show()

plt.figure(figsize=(5, 3))
plt.bar(model_names, f1_positive)
plt.ylabel("F1-score (class 1: diabetes)")
plt.ylim(0, 1)
plt.title("F1-score for positive class by model")
plt.xticks(rotation=15)
plt.tight_layout()
plt.show()
```

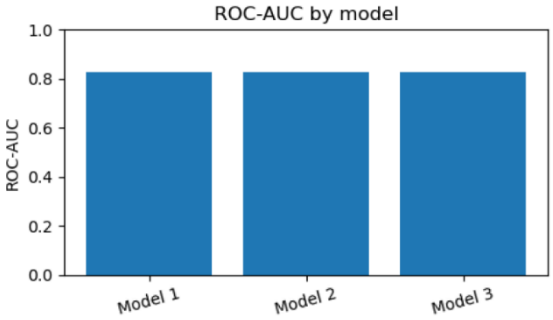

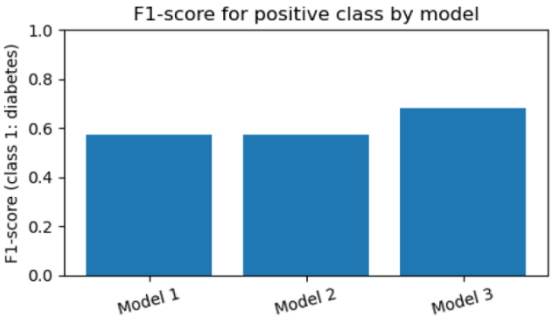

세 가지 파라미터 조합(Model 1~3)에 대해 동일한 학습/테스트 데이터를 사용해 모형을 학습하였다. 이후 각 모형의 ROC-AUC와 당뇨 클래스(1)에 대한 F1-score를 막대그래프(bar chart)로 시각화하였다. 이를 통해 규제 강도(C 값)와 클래스 가중치 설정이 전체 분류 성능과 양성 클래스 탐지 성능에 어떤 차이를 만드는지 한눈에 비교할 수 있었다.

위 그래프는 세 가지 로지스틱 회귀 모형(Model 1: 기본 L2, Model 2: 강한 L2, Model 3: 클래스 가중치 적용)에 대해 ROC-AUC와 당뇨 클래스에 대한 F1-score를 비교한 결과이다. 먼저 ROC-AUC는 세 모형 모두 약 0.82 수준으로 매우 유사하여, 전반적인 분류 능력은 하이퍼 파라미터 설정에 크게 영향을 받지 않는 것으로 나타났다. 반면, 양성 클래스에 대한 F1-score는 Model 3에서 가장 높게 나타나, 클래스 불균형을 보정한 설정이 당뇨 환자를 보다 잘 탐지하는 데 유리함을 확인할 수 있었다. 이에 본 연구에서는 세 모형 중 성능이 상대적으로 안정적이면서도 양성 클래스에 대한 예측력이 우수한 Model 3을 기준 모형으로 선택하고, 이후 계수 및 승산비 해석은 **Model 3**의 결과를 중심으로 수행하였다.

5. 제시된 문제에 대한 데이터 분석 및 결론

(1) 데이터 분석 (질문에 대한 답 도출)

```
best_result = max(results, key=lambda r: r["auc"])
best_coef_df = best_result["coef_df"].head(10)

plt.figure(figsize=(5, 4))
plt.barh(best_coef_df["feature"], best_coef_df["coef"])
plt.axvline(0, linestyle="--")
plt.xlabel("Coefficient")
plt.title(f"Top 10 coefficients ({best_result['name']})")
plt.gca().invert_yaxis()
plt.tight_layout()
plt.show()
```

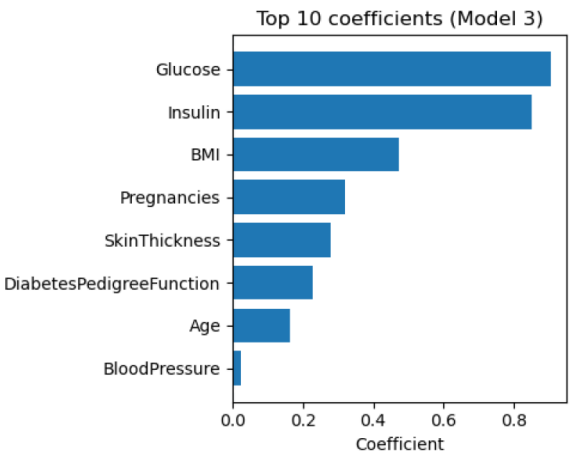

세 모형 중 ROC-AUC가 가장 높은 모형을 선택한 뒤, 해당 모형에서 계수의 절댓값이 큰 상위 10개 변수를 막대그래프로 시각화하였다. 양의 계수는 값이 증가할수록 당뇨일 승산을 높이는 방향, 음의 계수는 승산을 낮추는 방향의 영향을 의미한다. 이 그래프를 통해 Glucose, BMI, Insulin, Age, Pregnancies 등 주요 변수들이 당뇨병 진단에 상대적으로 어느 정도의 영향을 미치는지 직관적으로 비교할 수 있어, 연구 질문 ①에 대한 근거 자료로 활용하였다.

위 그래프는 성능이 가장 우수했던 Model 3에서 계수의 절댓값이 큰 상위 변수들을 막대그래프로 나타낸 것이다. 그래프를 보면 Glucose, Insulin, BMI의 계수가 다른 변수들에 비해 뚜렷하게 크며 모두 양수이다. 이는 다른 조건이 동일할 때, 이 세 변수의 값이 증가할수록 당뇨병일 승산이 가장 크게 증가한다는 것을 의미한다.

그 다음으로는 Pregnancies, SkinThickness, DiabetesPedigreeFunction, Age가 중간 정도의 양의 계수를 보여, 이들 역시 당뇨병 진단에 일정 부분 기여하지만 그 영향력의 크기는 Glucose·Insulin·BMI보다 작다. 반면 BloodPressure의 계수는 0에 매우 가깝게 나타나, 본 데이터셋에서는 혈압이 다른 변수들에 비해 상대적으로 제한적인 영향을 미치는 요인으로 해석된다.

따라서 연구 질문 ①인 "각 요인이 당뇨병 진단(Outcome)에 미치는 상대적 영향은 어느 정도인가?"에 대해, Glucose가 가장 큰 영향을 미치며, 그 다음으로 Insulin과 BMI가 중요한 위험 요인으로 작용한다고 정리할 수 있다. Pregnancies, SkinThickness, DiabetesPedigreeFunction, Age는 보조적인 영향력을 가지며, BloodPressure는 이들에 비해 영향력이 비교적 작은 변수로 나타났다.

```python
main_vars = ["Glucose", "BMI", "Insulin", "DiabetesPedigreeFunction"]

aux_vars = ["Age", "Pregnancies", "BloodPressure", "SkinThickness"]

all_vars = main_vars + aux_vars

corr = train[all_vars].corr(method="pearson")

sub_corr = corr.loc[aux_vars, main_vars]

print("\n<보조 변수들(Age 등)과 주요 요인 간 상관계수>")
print(sub_corr)

plt.figure(figsize=(6, 4))
plt.imshow(sub_corr, vmin=-1, vmax=1)
plt.colorbar(label="Correlation")
plt.xticks(range(len(main_vars)), main_vars, rotation=30)
plt.yticks(range(len(aux_vars)), aux_vars)
plt.title("Correlation between auxiliary variables and main risk facto
plt.tight_layout()
plt.show()
```

```
<보조 변수들(Age 등)과 주요 요인 간 상관계수>
                Glucose       BMI   Insulin  DiabetesPedigreeFunction
Age            0.291619  0.030259  0.153034                  0.025108
Pregnancies    0.140044  0.015981  0.099564                 -0.051994
BloodPressure  0.222328  0.272633  0.107687                 -0.005018
SkinThickness  0.258584  0.560061  0.272089                  0.112087
```

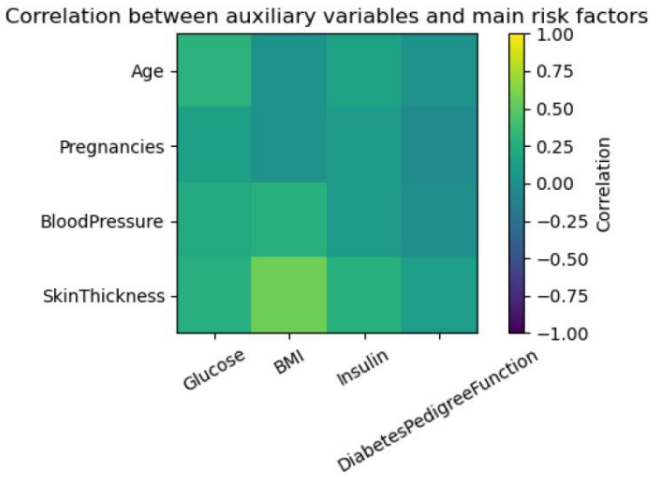

연구 질문 ②는 "Age(나이) 등의 보조 변수는 주요 요인들과 어떤 상관관계를 가지는가?"이다. 이를 확인하기 위해 보조 변수 Age, Pregnancies, BloodPressure, SkinThickness와 주요 위험 요인 Glucose, BMI, Insulin, DiabetesPedigreeFunction 간의 피어슨 상관계수를 표와 히트맵으로 나타내었다. 전반적으로 상관계수의 절댓값이 0.3 이하로 크지 않아, 보조 변수들이 주요 요인들과 강한 선형 관계를 갖지는 않음을 알 수 있다.

조금 더 구체적으로 보면, Age는 Glucose(약 0.29)와 Insulin(약 0.15)과는 약한 양의 상관을 보이지만, BMI나 DiabetesPedigreeFunction과의 상관은 거의 0에 가까워 뚜렷한 선형 패턴이 나타나지 않는다. Pregnancies는 Glucose와 약한 양의 상관(≈0.14)을 가지나, 다른 변수들과의 상관은 매우 미약하다. BloodPressure 역시 Glucose, BMI와는 약한 양의 상관(≈0.22~0.27)을 보이지만, Insulin 및 DiabetesPedigreeFunction과의 상관은 거의 없는 수준이다. 반면 SkinThickness는 BMI와 비교적 높은 양의 상관(≈0.56)을 보여, 체지방과 체질량이 함께 증가하는 경향을 어느 정도 반영하는 변수로 해석할 수 있다.

이러한 결과를 종합하면, 연구 질문 ②인 "Age 등의 보조 변수는 주요 요인들과 어떤 상관관계를 가지는가?"에 대해, 보조 변수들은 대부분 주요 위험 요인들과 약한 수준의 상관만을 가지며, 특히 SkinThickness–BMI를 제외하면 강한 선형 관계는 관찰되지 않는다고 정리할 수 있다. 따라서 Age, Pregnancies, BloodPressure, SkinThickness는 Glucose·BMI·Insulin·DiabetesPedigreeFunction을 직접 대체하는 핵심 위험 요인이라기보다는, 당뇨병 위험을 설명할 때 함께 고려할 수 있는 배경·보조 변수의 성격을 가진다고 볼 수 있다.

```python
target_vars = ["BMI", "Insulin", "DiabetesPedigreeFunction"]

rows = []
for r in results:
    for feat in target_vars:
        odds = r["coef_df"].loc[r["coef_df"]["feature"] == feat, "odds_ratio"].v
        rows.append({"model": r["name"], "feature": feat, "odds_ratio": odds})

odds_df = pd.DataFrame(rows)

for feat in target_vars:
    sub = odds_df[odds_df["feature"] == feat]
    plt.figure(figsize=(5, 3))
    plt.bar(sub["model"], sub["odds_ratio"])
    plt.ylabel("Odds ratio")
    plt.title(f"Odds ratio of {feat} by model")
    plt.xticks(rotation=15)
    plt.tight_layout()
    plt.show()
```

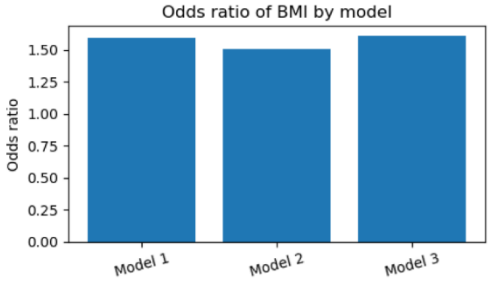

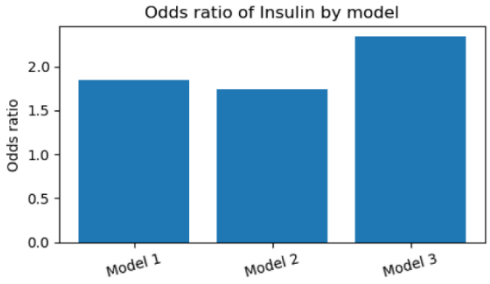

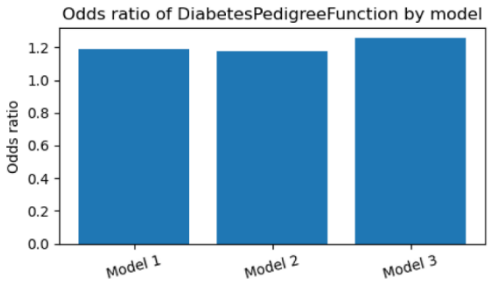

연구 질문 ③은 "유전적 요인보다 BMI와 인슐린 수치가 더 큰 영향을 보이는가?"이다. 이를 위해 각 모형에서 BMI, Insulin, DiabetesPedigreeFunction의 승산비를 추출하고, 변수별로 모형 간 승산비를 막대그래프로 나타냈다. 세 모형에서 공통적으로 BMI와 Insulin의 승산비가 유전 요인보다 크거나, 계수의 절댓값이 더 큰 경향을 보인다면, "BMI와 인슐린 수치가 유전적 요인보다 당뇨병 진단에 더 강하게 관련된다"는 결론을 시각적으로 뒷받침할 수 있다.

위 그래프 세 개는 세 가지 로지스틱 회귀 모형(Model 1~3)에 대해 BMI, Insulin, DiabetesPedigreeFunction의 odds ratio를 비교한 결과이다. 세 그래프 모두에서 BMI의 odds ratio는 대략 1.5 내외로 유지되며, Insulin의 odds ratio는 모델에 따라 약 1.7~2.3 수준으로 가장 크게 나타난다. 반면 DiabetesPedigreeFunction의 odds ratio는 세 모형 모두에서 1.1~1.2 정도로, 1에서 약간만 증가한 수준에 머문다. 이는 동일한 조건에서 각 변수가 1단위 증가할 때, Insulin와 BMI가 DiabetesPedigreeFunction에 비해 당뇨병일 승산을 더 크게 증가시키는 방향으로 작용한다는 것을 의미한다. 세 모형의 설정이 달라져도 이러한 관계가 일관되게 유지된다는 점에서, 연구 질문 ③인 "유전적 요인보다 BMI와 인슐린 수치가 더 큰 영향을 보이는가?"에 대해, 본 데이터에서는 BMI와 Insulin이 유전적 요인보다 상대적으로 더 강한 영향력을 갖는 위험 요인으로 나타난다고 결론 내릴 수 있다.

(2) 결론

본 프로젝트의 최종 목표는 "당뇨병 발병에 영향을 미치는 요인들 중에서 어떤 요인이 더 큰 영향을 미치는지 분석하는 것"이었다. 이를 위해 "유전적 요인보다 BMI와 Insulin 수치가 당뇨병 발병에 더 큰 영향을 미칠 것이다"라는 연구 가설을 설정하고, 다음 세 가지 연구 질문을 중심으로 분석을 진행하였다.

앞선 분석 결과를 간단히 정리하면, 연구 질문 ①에 대해서는 Glucose가 가장 큰 영향을 미치는 변수로 나타났고, 그 다음으로 Insulin과 BMI가 중요한 위험 요인으로 추정되었다. 연구 질문 ②에서는 Age, Pregnancies, BloodPressure, SkinThickness 등 보조 변수들이 주요 위험 요인과 전반적으로 약한 상관관계만을 보여, 강한 선형 관계를 갖는 변수는 제한적이라는 점을 확인하였다. 연구 질문 ③에서는 세 가지 모델 모두에서 BMI와 Insulin의 odds ratio가 DiabetesPedigreeFunction보다 일관되게 더 크게 나타나, BMI와 Insulin이 유전적 요인보다 상대적으로 강한 영향력을 가진다는 결과를 얻었다.

연구 가설에 대한 결론을 내리면, 본 데이터셋과 Logistic Regression 모형의 범위 내에서 "유전적 요인보다 BMI와 Insulin 수치가 당뇨병 발병에 더 큰 영향을 미칠 것이다"라는 가설은 전반적으로 지지된다고 볼 수 있다. 특히 Glucose, Insulin, BMI가 공통적으로 상위 영향 변수로 나타났고, DiabetesPedigreeFunction은 유의한 양의 방향의 영향은 가지지만, 그 크기는 상대적으로 작게 추정되었다는 점에서, 체질량과 인슐린 대사 관련 요인이 유전적 배경보다 더 직접적으로 당뇨병 진단과 연결되어 있음을 시사한다

아쉬운 점으로는 단일 데이터셋과 하나의 선형 모형(Logistic Regression)에만 기반한 분석이라는 한계가 있으며, 반면 각 변수의 계수와 odds ratio를 통해 당뇨병 위험 요인의 상대적 중요도를 구체적으로 확인할 수 있었다는 점은 흥미로웠다.